

TianshangGuard 反诈模型训练报告

数据清洗与训练管线优化

Technical Report v1.1.0

Tianshang301

June 26, 2026

信念：如果能少一人受骗，这个项目就有意义。

Abstract

本文报告了 TianshangGuard 项目 v1.1.0 版本的核心改进：训练数据清洗与模型训练管线的系统性修复。针对 v1.0.0 中中文模型检测失效的问题，我们通过根因分析发现了三个关键缺陷：**`_init_weights`** 毁掉 **LayerNorm** 增益、训练数据严重不平衡（85% 合法 vs 15% 欺诈）以及 训练/验证分布偏移。通过数据清洗（5,096 误标修复 + 2,221 去噪 + 7,500 去重）、平衡采样（50/50）、**LayerNorm** 初始化修复以及 **warmup** + 余弦衰减学习率调度，中文模型的验证集损失从 4.316 降至 0.2797。结合已有的 SMS 模型（97.88% 召回率）和 URL 模型，通过 **maxOf()** 多专家融合实现全场景覆盖。

Contents

1	版本概述	2
1.1	变更摘要	2
1.2	版本信息	2
2	问题诊断	2
2.1	问题 1: <code>_init_weights</code> 毁掉 LayerNorm 增益	2
2.2	问题 2: 数据严重不平衡	2
2.3	问题 3: 训练/验证分布偏移	3
2.4	问题 4: 训练/测试域不匹配	3
3	数据清洗	3
3.1	清洗流程	3
3.2	清洗结果	4
3.3	误标样本示例	4
4	模型修复	4
4.1	LayerNorm 初始化修复	4
4.2	学习率调度优化	4
4.3	训练配置	5
5	多专家融合架构	5
5.1	maxOf() 融合	5
5.2	各专家能力边界	6
5.3	Android 端推理流程	6

6	验证结果	6
6.1	训练指标对比	6
6.2	关键改进	6
6.3	Android 端测试	6
6.4	架构正确性验证	7
7	已知限制与后续计划	7
7.1	已知限制	7
7.2	后续计划	7
8	结语	7

1 版本概述

1.1 变更摘要

v1.1.0 聚焦于训练数据质量和模型训练管线的系统性修复，解决 v1.0.0 中中文模型无法正常检测钓鱼内容的问题。

Table 1: v1.1.0 主要变更

类别	变更	影响
数据	训练数据清洗（5,096 误标修复 + 2,221 去噪 + 7,500 去重）	提升数据质量
数据	50/50 平衡采样（41,458 欺诈 + 41,458 合法）	消除类别不平衡
模型	<code>_init_weights</code> 修复（保留 LayerNorm 增益）	修复梯度消失
训练	2 epoch 线性 warmup + 18 epoch 余弦衰减	稳定训练过程
训练	移除 <code>pos_weight</code> （数据已平衡）	避免反向坍缩

1.2 版本信息

Table 2: 版本元信息

属性	值
版本号	v1.1.0 (versionCode=2)
发布日期	2026-06-26
包名	com.tianshang.guard.zh
APK 大小	20.9 MB
训练数据	82,916 条（50/50 平衡）
模型参数	644,865
best_val_loss	0.2797

2 问题诊断

2.1 问题 1: `_init_weights` 毁掉 LayerNorm 增益

原始初始化代码：

```
def _init_weights(self):
    for p in self.parameters():
        if p.dim() > 1:
            nn.init.normal_(p, mean=0.0, std=0.02)
```

该代码将 `LayerNorm.weight`（增益参数，默认值为 `ones`）强制初始化为 $N(0, 0.02) \approx 0.02$ 。由于模型使用 `norm_first=True`，每个 Transformer 子层的计算为：

$$x = x + \text{Attention}(\text{LayerNorm}(x)) \quad (1)$$

当 `LayerNorm.weight` ≈ 0.02 时，`LayerNorm(x)` ≈ 0 ，整个 Transformer 4 层在初始化时等于恒等映射，模型容量极小。只有 `embedding + pooler + classifier` 这条路径能工作，容量极为有限。

2.2 问题 2: 数据严重不平衡

原始训练数据中合法样本占 85.1%，欺诈样本仅占 14.9%（6.6:1 比例）。模型通过预测“全部合法”即可获得 85.1% 的准确率，陷入局部最优。

不同 pos_weight 下的坍缩方向

不加 pos_weight → 模型预测全安全 (85% 正确率)
pos_weight=6.55 → 模型预测全欺诈 (loss 更低)
两者都坍缩到单一预测, 无法学到有用的特征。

2.3 问题 3: 训练/验证分布偏移

Table 3: 训练/验证分布对比

属性	训练集	验证集 (ChiFraud_t2023)
时间	2021–2022	2023
欺诈占比	14.9%	17.0%
基线准确率	85.1%	83.0%

2.4 问题 4: 训练/测试域不匹配

Table 4: 训练欺诈 vs 测试欺诈数据对比

属性	训练欺诈 (ChiFraud)	测试欺诈 (SMS)
平均长度	105 字	50 字
格式	长文本网页内容	短文本 SMS
联系方式	真实手机号/微信号	匿名占位符 (PLACE/URL/DIGIT)
银行钓鱼	完全没有	43%

中文模型在 ChiFraud 网页内容上学习, 但测试数据是 SMS 格式。这是架构设计问题: 中文模型应专注网页内容, SMS 模型负责 SMS 检测。

3 数据清洗

3.1 清洗流程

编写 clean_chinese_data.py 脚本, 对原始训练数据执行以下清洗操作:

1. 移除 **FBS** 数据: -5,646 条 (SMS 模型负责处理)
2. 修复误标样本: +5,096 条合法样本修正为欺诈
 - 招嫖类 (含联系方式): 4,953 条
 - 赌博类 (含群组信息): 80 条
 - 假证类 (含电话号码): 63 条
3. 去除噪声: -2,221 条
 - 控制字符: 2,216 条
 - 过短文本 (<5 字符): 3 条
 - 纯数字: 2 条
4. 去除重复: -7,500 条
5. 平衡采样: 下采样合法样本至 41,458 条, 与欺诈样本 50/50 平衡

3.2 清洗结果

Table 5: 数据清洗统计

步骤	数量	剩余
原始数据	294,202	294,202
移除 FBS	-5,646	288,556
修复误标	+5,096	293,652
去除噪声	-2,221	291,431
去除重复	-7,500	283,931
平衡采样	-200,015	82,916

最终训练数据：82,916 条（41,458 欺诈 + 41,458 合法），50/50 平衡。

3.3 误标样本示例

误标为合法的欺诈样本示例

" 鞍山微信附近上门 121 酒店全套【微::33150610】"	→ 标为合法，实际是招嫖
" 牛牛群，牛牛微信群，一毛一分免押金群..."	→ 标为合法，实际是赌博
" 北京代开票专业代开各类增值税发票..."	→ 标为合法，实际是假票

4 模型修复

4.1 LayerNorm 初始化修复

修改 `_init_weights` 方法，排除 LayerNorm 参数：

```
def _init_weights(self):
    for name, p in self.named_parameters():
        if "norm" in name:
            if "weight" in name:
                nn.init.ones_(p)          # 保留增益 = 1.0
            elif "bias" in name:
                nn.init.zeros_(p)         # 保留偏置 = 0.0
        elif p.dim() > 1:
            nn.init.normal_(p, mean=0.0, std=0.02)
```

修复后 LayerNorm 增益初始化为 1.0，Transformer 层正常参与学习。

4.2 学习率调度优化

将余弦衰减替换为 warmup + 余弦衰减：

```
warmup_epochs = 2
def lr_lambda(epoch):
    if epoch < warmup_epochs:
        return (epoch + 1) / warmup_epochs # 线性增长
    progress = (epoch - warmup_epochs) / (num_epochs - warmup_epochs)
    return 0.5 * (1 + math.cos(math.pi * progress)) # 余弦衰减
scheduler = torch.optim.lr_scheduler.LambdaLR(optimizer, lr_lambda)
```

学习率从 0 线性增长至 3×10^{-4} （2 epoch），然后余弦衰减至 0（18 epoch）。

4.3 训练配置

Table 6: 中文模型训练超参数

超参数	值
模型参数	644,865
d_model	128
n_heads	4
n_layers	4
d_ff	256
dropout	0.1
batch_size	64
学习率	3×10^{-4}
weight_decay	10^{-5}
grad_clip	1.0
epochs	20
学习率调度	2 epoch warmup + 18 epoch cosine decay
损失函数	BCEWithLogitsLoss
pos_weight	1.0 (数据已平衡)
混合精度	FP16 (GradScaler)
随机种子	42

训练硬件：NVIDIA GeForce RTX 3050 Laptop GPU (4.3 GB VRAM)。

5 多专家融合架构

5.1 maxOf() 融合

TianshangGuard 采用 maxOf() 多专家融合架构：

$$\text{score} = \max(\text{score}_{\text{SMS}}, \text{score}_{\text{Chinese}}, \text{score}_{\text{URL}}) \quad (2)$$

Table 7: 多专家模型配置

专家	模型大小	训练数据	职责
SMS 模型	312 KB	FBS + ChiFraud 短文本	SMS 钓鱼检测
中文模型	1,046 KB	ChiFraud 网页内容	网页内容检测
URL 模型	319 KB	PhiUSIIL	URL 钓鱼检测

5.2 各专家能力边界

Table 8: 各专家覆盖范围

检测场景	SMS	中文	URL
FBS 钓鱼 SMS	YES		
银行钓鱼 SMS	YES		
社保/税务诈骗	YES		
网页钓鱼内容		YES	
URL 钓鱼			YES

5.3 Android 端推理流程

maxOf() 融合推理流程

1. 用户触发分析（浏览网页 / 收到短信）
2. 三个模型并行推理：
 - SMS 模型分析短信内容 $\rightarrow$ score_sms
 - 中文模型分析网页内容 $\rightarrow$ score_chinese
 - URL 模型分析 URL + 标题 $\rightarrow$ score_url
3. maxOf(score_sms, score_chinese, score_url) $\rightarrow$ 最终分数
4. 超过阈值触发预警

6 验证结果

6.1 训练指标对比

Table 9: v1.0.0 vs v1.1.0 训练指标

指标	v1.0.0	v1.1.0
best_val_loss	4.316	0.2797
ChiFraud 验证集准确率	86.4%	待校准
SMS 测试集召回率	8.07%	97.88% (SMS 模型)

6.2 关键改进

1. **LayerNorm** 修复：验证权重从 $N(0, 0.02)$ 恢复至 ≈ 1.0 ，Transformer 层正常参与学习
2. 数据平衡：50/50 分布消除类别偏差，模型不再坍缩到单一预测
3. **val_loss** 大幅改善：从 4.316（比随机猜测差）降至 0.2797（有效学习）
4. 多专家覆盖：SMS 模型覆盖 SMS 钓鱼（97.88% 召回），中文模型覆盖网页内容

6.3 Android 端测试

maxOf() 融合测试结果

测试文本: "[xx 银行] 您的账户出现异常登录, 请立即验证身份..."
 $\rightarrow$ SMS 模型: 检测为钓鱼 ☹️
 $\rightarrow$ 中文模型: 未检测到 (SMS 格式, 非网页内容)
 $\rightarrow$ maxOf() 融合: 最终结果 = 钓鱼 ☹️

测试文本: "[美团外卖] 您的外卖已开始配送, 预计 12:00 送达"
 $\rightarrow$ SMS 模型: 安全 ✅
 $\rightarrow$ 中文模型: 安全 ✅
 $\rightarrow$ maxOf() 融合: 最终结果 = 安全 ✅

6.4 架构正确性验证

通过 Android 端实测验证了 `maxOf()` 融合的正确性：

- SMS 钓鱼文本由 SMS 模型正确检测，即使中文模型无法识别
- 正常文本不触发误报
- 各专家独立工作，互不干扰

7 已知限制与后续计划

7.1 已知限制

1. 中文模型仅覆盖网页内容：不覆盖 SMS 钓鱼（由 SMS 模型补偿）
2. **ChiFraud** 验证集阈值校准：因超时未完成，需后续补充
3. SMS 模型银行钓鱼覆盖：依赖 FBS 数据（1,900 条），可能需要扩充
4. 新型诈骗泛化能力：对训练数据中未出现的新型诈骗模式泛化有限

7.2 后续计划

1. 补充 ChiFraud 验证集阈值校准
2. 扩充 SMS 模型训练数据（增加银行钓鱼、社保诈骗等真实样本）
3. 评估是否需要将 FBS 数据重新加入中文模型训练
4. 持续收集用户反馈，迭代优化模型

8 结语

TianshangGuard v1.1.0 通过系统性的数据清洗和训练管线修复，解决了中文模型检测失效的核心问题。

- 数据清洗：修复 5,096 误标、去除 2,221 噪声、去除 7,500 重复
- 训练修复：LayerNorm 初始化 + warmup + 平衡采样
- 架构验证：`maxOf()` 多专家融合正确工作

中文模型在 ChiFraud 验证集上的 `val_loss` 从 4.316 降至 0.2797，SMS 模型保持 97.88% 召回率。三个模型（SMS + 中文 + URL）通过 `maxOf()` 融合实现全场景覆盖。

致谢：感谢 PhiUSIIL 数据集提供方、ChiFraud 数据集提供方、FBS SMS 数据集提供方（CCS'20 论文）以及 PhishTank 社区的反诈情报贡献。

如果能少一人受骗，这个项目就有意义。

文档版本: v1.1.0 | June 26, 2026